

MT-LNN: 受微管启发的液态神经网络架构

融合全局工作区理论瓶颈与麻醉验证测试

AN MUNING¹

¹Everest Research

e@awareness.market

<https://github.com/everest-an/01>

2026 年 5 月

摘要

我们引入了 MT-LNN (Microtubule-Inspired Liquid Neural Network, 受微管启发的液态神经网络), 这是一种融合了三大前沿科学理论的神经架构: 神经元微管 (MTs) 的计算作用、闭式液态时间常数网络 (CfLTC) 以及意识的全局工作区理论 (GWT)。MT-LNN 将标准 Transformer 中的前馈网络 (FFN) 替换为微管动态层 (MT-DL) ——13 个平行的 CfLTC 通道, 具有多尺度共振 ($P \times S$ 库), 三向横向耦合 (静态恒等式 + 通过 `torch.roll` 的同步最近邻 + 结合内容的 RMC 注意力), 周期性 GTP 帽更新以及 MAP 蛋白稳定门。一个微管注意力模块将标量和可选的低秩双线性极性偏置与类似 ALiBi 的每头 GTP 衰减门融合。一个全局工作区理论瓶颈 (GWTB) 将表示压缩至 $d_{gw} \ll d_{model}$, 在因果工作区中进行处理, 并进行全局广播。互补的全局相干层应用稀疏 top- k 注意力和受 Orch-OR 启发的坍缩门。此外, 我们提出了一套麻醉验证协议 (AVP): 运行时前向钩子函数在模拟麻醉水平升高时逐步抑制 MT-DL 输出和全局广播, 随后我们测量 $\hat{\phi}$ (基于 kNN 的信息整合指标) 作为生物标志物。该递归还支持逐步流逝时间 Δt (衰减 $\exp(-\Delta t/\tau)$), 因此架构可原生处理不规则采样/连续时间输入。我们发布一个经完整单元测试的实现 (57 项 CPU + 42 项 CUDA 断言, 含并行扫描递归的逐位精确校验与 Δt 路径的逐位向后兼容), 以及在单张消费级 GPU 上覆盖 Selective Copy、状态跟踪、WikiText-103、ETT 预测、合成不规则采样探针和 PhysioNet-2012 ICU 死亡率的诚实、可复现评测。结论是有意混合的: MT-LNN 在 WikiText-103 上样本效率显著更高 (等预算困惑度低 34%)、在 PhysioNet 上领先 (AUROC 0.823 vs 0.797/0.777, 与 CfC/LTC 文献一致); 纯液态层在低维 ETT 回归上最好; 三者 Selective Copy 上相当; 连续时间 Δt 进 decay 机制在合成任务上决定性有效, 但在 Δt 已作特征的临床数据上冗余。AVP 作为架构指纹发挥作用 (只有 MT-LNN 的 $\hat{\phi}$ 响应, 基线恒为零), 而非已通过的性能测试——我们坦诚讨论了 toy 规模估计器局限。所有代码与权重均已开源。

关键词: 液态神经网络, 微管, 全局工作区理论, 整合信息理论, 意识, 麻醉验证。

1 引言

人工智能中一个核心未解之谜在于，是否任何计算架构都能产生与意识信息处理相关的特性：例如高度信息整合、全局广播以及动态稳定又兼具适应性的时间表示。

整合信息理论 (IIT, Tononi 2004) 将意识等同于 Φ ，即系统不可还原为局部之和的整合信息量。全局工作区理论 (GWT, Baars 1988, Dehaene et al. 2011) 则认为，当信息从狭窄的瓶颈广播至大量专用处理器时，有意识的访问便产生了。这两大理论均对神经架构提出了原理性预测。

第三个更具争议的理论指出，神经元微管可能是意识的物理基质。Orch-OR 假说 [?Hameroff & Penrose, 2014] 提出微管蛋白二聚体中的量子叠加态由于量子引力而坍缩，产生离散的意识瞬间。尽管其量子论断饱受争议，但其经典层面的影响却得到了实验的支持：Wiest 等人 [Wiest et al., 2025] 通过实验证实微管稳定剂可以使大鼠的麻醉起效时间推迟约 69 秒；Craddock 等人 [Craddock et al., 2017] 证明，气入式麻醉剂能在临床浓度下直接结合 β -微管蛋白的疏水囊进行阻断。

主要贡献。 MT-LNN 做出了如下贡献：

- C1 微管动态层 (MT-DL).** 13 根原纤维并行的 C_{FL}TC 设计，具备 $P \times S$ 多尺度共振库、三向横向耦合、周期性 GTP 帽更新与 MAP 蛋白门控——所有操作在 P 维度通过单次 einsum 完成向量化。
- C2 微管注意力.** 基于 SDPA 的 GQA，附带标量极性偏置以及具有 ALiBi 风格的 per-head GTP 级联衰减。
- C3 GWTB + 整体相干层.** 容量受限的全局工作区，与附带稀疏门控坍缩机制的相干层协同工作。
- C4 麻醉验证协议 (AVP).** 首个通过计算模拟临床麻醉效果的协议，其引入了基于 kNN 的 $\hat{\Phi}$ 近似计算。
- C5 工程级实现.** Flash-Attention, 双态 KV 缓存, 持久化会话缓存, 以及高效的并行扫描训练算法。

2 相关工作

连续时间网络基础由 Neural ODEs 奠定 [Chen et al., 2018]。闭式方程 C_{FL}TC [?] 消除了求解器开销。在长文本状态空间中，Mamba [Gu & Dao, 2023] 实现了超越 Transformer 的效率。而本研究的架构进一步引入了微管的动态仿生。

3 MT-LNN 架构

概述。

$$\mathbf{x} \xrightarrow{\text{Embed+RoPE}} \left[\text{MicrotubuleAttn} \rightarrow \text{MT-DL} \right]^{n_{\text{layers}}} \rightarrow \text{GWTB} \rightarrow \text{GlobalCoherence} \rightarrow \text{LN} \rightarrow \text{lm_head}$$




图 1: MT-LNN 架构概述。输入表示依次经过微管动态层（结合了 13 个平行的原丝，建模为具有横向量子耦合的 CfLTC 通道）、通过局部状态调节序列门控的微管注意力（Microtubule Attention）模块，以及建立全局整合广播的全局工作空间理论瓶颈（Global Workspace Theory Bottleneck）。最顶层的全局相干层（Global Coherence Layer）实现了 Orch-OR 坍塌。

每个块对两个子层应用前置归一化（pre-norm）和残差连接。一个 ModelCacheStruct 携带着每一层的注意力 KV、每一层的 h_{prev} 、GWTB 工作空间 KV，以及全局相干 KV。

3.1 微管动态层 (MT-DL)

原丝分解。 输入 $\mathbf{x} \in \mathbb{R}^d$ 被投影到 $d_{\text{proto_total}} = P \cdot D$ （其中 $D = \lceil d/P \rceil$ ）并划分为 $P = 13$ 个通道 $\mathbf{x}_1, \dots, \mathbf{x}_P \in \mathbb{R}^D$ 。所有 $P \times S$ 个 LTC 库在权重张量 $W_{\text{in}} \in \mathbb{R}^{P \times S \times D \times D}$ 上通过单次 *einsum* 进行求值。

多尺度共振。 每根原丝 p 运行 $S = 5$ 个 CfLTC 子库，其时间常数呈几何级数扫描：

$$\tau_s = \tau_{\min} (\tau_{\max} / \tau_{\min})^{s/(S-1)}, \quad s = 0, \dots, S-1, \quad (1)$$

默认值为 $\tau_{\min} = 0.01$, $\tau_{\max} = 10$ 。每个 (p, s) 库遵循公式 (??)。输出通过学习到的每根原丝对参数 $\text{blend_weights} \in \mathbb{R}^{P \times S}$ 进行的 softmax 进行混合（初始化为 0，即在初始化时均匀混合）。

三向横向耦合。

$$\text{residual} = W_{\text{lat}} \mathbf{h}, \quad W_{\text{lat}} \in \mathbb{R}^{P \times P}, \quad \text{init} = I + \epsilon, \quad (2)$$

$$\text{nearest} = \eta \cdot \tanh(W_L \text{roll}(\mathbf{h}, +1) + W_R \text{roll}(\mathbf{h}, -1)), \quad (3)$$

$$\text{RMC} = \sigma(\text{rmc_gate}) \cdot \text{SDPA}(q(\mathbf{h}), k(\mathbf{h}), v(\mathbf{h})), \quad (4)$$

其中 `roll` 沿着原丝轴进行，提供了同步的最近邻耦合，而没有从左到右的偏差。`rnc_gate` 初始化为 -3 ，因此 $\sigma(-3) \approx 0.05$ 。

GTP 帽更新。 时间门控乘以总的横向贡献：

$$\text{gtp_scale}(t) = \exp(-\gamma \cdot (t \bmod T_{\text{period}})), \quad T_{\text{period}} = 256. \quad (5)$$

如果没有周期性的取模运算， $\exp(-\gamma t) \rightarrow 0$ 会在经过几千个位置后导致横向混合在长上下文中悄无声息地消失。公式 (5) 模拟了 GTP 帽的更新：新的 GTP 帽随着微管蛋白的聚合而周期性地形成。

MAP 蛋白稳定门。 每根原丝一个双层 MLP（实现为批量 `einsum`）：

$$s_p = \sigma(W_2^{(p)} \text{ReLU}(W_1^{(p)}[\mathbf{h}_p; \mathbf{x}_p] + b_1^{(p)}) + b_2^{(p)}) \in (0, 1), \quad (6)$$

其中 $b_2^{(p)}$ 初始化为 $+2$ ，因此 $\sigma(2) \approx 0.88$ ：门控在开始时接近完全打开，并学习进行抑制，从而防止梯度饥饿。输出为： $\mathbf{h}_p \leftarrow s_p \cdot \mathbf{h}_p$ 。

并行扫描训练。 在训练期间，递归 $h_t^{(p,s)} = d_{p,s} \cdot h_{t-1}^{(p,s)} + X_t^{(p,s)}$ 通过 Blelloch 前缀扫描沿 T 并行求解 [Blelloch, 1990]。对于恒定衰减的情况（ $d_{p,s}$ 与 t 无关，这是我们的默认设置），该扫描转化为闭式前缀乘积：

$$h_t = d^t h_0 + \sum_{i=0}^{t-1} d^{t-i} X_i, \quad (7)$$

计算的总工作量为 $O(T \log T)$ ，顺序深度为 $O(\log T)$ 。常数 A 特化版（`pscan_constant_A`）广播标量衰减，而无需具体化完整的 $(\dots, T)$ 张量，避免了在 $P \times S$ 库中进行与 T 成正比的内存分配。这将训练并行度提升到了与 Mamba/S5 相同的渐近水平，且不需要 Triton 内核。

复杂性。 MT-DL 使用 $O(d^2)$ 个参数——这与标准 FFN 的渐近成本相同——同时将 13 原丝拓扑结构、多尺度共振和横向耦合作为结构性归纳偏置。将 P 从 13 增加到 64 在 CPU 上会增加约 20% 的运行时间（1.2 倍），这证实了主要计算工作发生在向量化的 GPU 内核中。

3.2 微管注意力 (Microtubule Attention)

多头因果注意力包含两个受微管启发的修改，折叠为传递给 `scaled_dot_product_attention` 的单次加性偏置（Flash-Attention / 内存高效后端自动处理）。

标量极性偏置。

$$b_{h,i,j}^{\text{pol}} = -\text{polarity}_h \cdot (i - j)/L, \quad \text{polarity}_h \in [-1, 1]. \quad (8)$$

可选的低秩双线性模式添加了 $\sigma(XW_A)(XW_B)^\top$ ，其中 $W_A, W_B \in \mathbb{R}^{d \times r}$ ，由每个头的 $\sigma(\text{gate}_h)$ 进行门控，该门控初始化为 $\sigma(-3) \approx 0.05$ 。

ALiBi 风格的 GTP 对数偏置。

$$b_{h,i,j}^{\text{GTP}} = -\gamma_h \cdot \max(i - j, 0), \quad (9)$$

其中 $\gamma_h = \gamma_0 \cdot 2^{\text{linspace}(3, -3, H)}$ ：头 0 具有强局部性 ($\approx 8\gamma_0$)，头 $H - 1$ 接近全局 ($\approx \gamma_0/8$) ——即 64 倍的感受野扩散。 γ_h 在运行时通过 softplus 进行正值化。

GQA 与 KV 缓存。 默认： $n_{\text{heads}} = 13$ ， $n_{\text{kv_heads}} = 1$ （多查询注意力），产生 $13\times$ 的 KV 缓存内存缩减。有符号距离矩阵 $\Delta_{ij} = i - j$ 和因果掩码是预先计算的缓冲区；解码期间没有每个 token 的内存分配。

3.3 全局工作空间理论瓶颈 (GWTB)

压缩（点火）。 $\mathbf{z}_t = \text{LN}(W_{\text{comp}} \mathbf{x}_t) \in \mathbb{R}^{d_{gw}}$ ，其中 $d_{gw} = d/r$ （默认 $r = 8$ ， $d_{gw} = 104$ ）。

工作空间自注意力。 在 d_{gw} 空间内带有 KV 缓存的因果多头自注意力 (SA)；在瓶颈处强制进行竞争性选择。

广播（全局点火）。

$$\mathbf{x}'_t = \mathbf{x}_t + \gamma_{\text{bcast}} \cdot W_{\text{bcast}} \mathbf{z}'_t, \quad (10)$$

其中 γ_{bcast} 初始化为 0.01（开始时接近恒等映射）。默认情况下，GWTB 在整个块堆叠之后应用一次；`gtwb_per_block=True` 会在每个块内部放置一个 GWTB，以实现逐层的点火语义。

3.4 现有 LLM 的 MT-LNN 残差适配器

为了在没有完整预训练的情况下评估 MT 的时间偏置，`llama_adapter.py` 提供了一个参数高效的适配器，可以包装任何 HuggingFace 因果语言模型 (LM)：

1. 冻结基础模型 (Llama、Mistral、Qwen2、GPT-2 等)。
2. 在每 k 个解码器层（默认 $k = 4$ ，并且始终包含最后一层）之后注入一个 `MTResidualAdapter`：

$$\tilde{\mathbf{h}}_t = \mathbf{h}_t + \alpha_{\text{init}} \cdot \text{MT-DL}(\text{LN}(\mathbf{h}_t)), \quad (11)$$

其中 $\alpha_{\text{init}} = 10^{-3}$ ，因此适配器在初始化时接近恒等映射。

3. 仅微调适配器（对于一个 7B 的基础模型，由于其大约占总参数的 0.5%）。

这允许社区将 MT 的时间动态性改造到任何开放权重的 LLM 上，并运行 AVP 麻醉测试而无需进行完整的训练过程。

3.5 量子横向耦合 (VQC 变体)

作为一项实验性扩展，`quantum_coupling.py` 将经典的 `LateralCoupling`（公式 3）替换为一个 P -量子比特变分量子电路 (VQC)，其纠缠拓扑结构反映了 MT B-晶格。

电路架构。 对于每个 (b, t) 样本：

1. **编码：**通过 W_{enc} 将 D -维状态 $\mathbf{h}_p \rightarrow (\theta_1, \theta_2, \theta_3)$ ；对每个量子比特应用 $R_X(\theta_1)R_Y(\theta_2)R_Z(\theta_3)$ 。
2. **变分量子电路 (VQC)：** $k = 2$ 层的（每个量子比特 $R_Y \cdot R_Z \cdot R_Y$ ）+ 环形 CNOT：对于 $i = 0, \dots, P - 1$ ，应用 $\text{CNOT}(i, i + 1 \bmod P)$ 。
3. **测量：**测量每个量子比特的 $\langle Z_i \rangle \in [-1, 1]$ 。
4. **解码：** $\langle Z_i \rangle \xrightarrow{W_{\text{dec}}} \mathbb{R}^D$ ；门控残差混合 $\mathbf{h}_p \leftarrow \mathbf{h}_p + \alpha \cdot \text{decoded}_p$ ， α 初始化为 0.05。

环形 CNOT 模式在量子比特层面上完全模拟了 13 原丝 B-晶格横向键。该电路通过 PennyLane TorchLayer [?] 是完全可微的，并可通过标准反向传播进行训练；未来的工作可以在不修改代码的情况下，将 default.qubit 替换为 lightning.gpu 或真实的 IBM Quantum / IonQ 硬件。

纯度诊断。 我们导出了 quantum_state_purity: $1 - \langle |\langle Z_i \rangle| \rangle$ ，这是一个纠缠代理指标——更高的值表明有更多的跨原丝纠缠。在训练期间可以跟踪此指标，作为 VQC 是否真正在利用量子结构的一个读数。

3.6 全局相干层 (Orch-OR 坍塌)

稀疏 top- k 因果注意力 ($k = \lceil T \cdot \text{sparsity} \rceil$ ，默认 10%)，具有学习到的坍塌门控：

$$\text{gate} = \sigma((\bar{e} - \theta) \cdot 10), \quad (12)$$

其中 $\bar{e}$ 是因果位置上的平均注意力能量， θ 是学习到的阈值。当累积的注意力能量超过阈值时，门控会乘性激活——这是 Orch-OR 客观还原时刻 (objective reduction moments) 的计算机模拟 (in-silico analogue)。门激活率会作为诊断信息导出。

4 麻醉验证协议 (AVP)

4.1 生物学动机

Wiest 等人 [Wiest et al., 2025] 报告称，埃坡霉素 B (epothilone B) 将麻醉起效时间推迟了约 69 秒，直接暗示了微管 (MT) 的破坏。Craddock 等人 [Craddock et al., 2017] 表明，在一系列广泛的化学物质中，麻醉效力与 β -微管蛋白的结合亲和力相关。

4.2 计算麻醉模拟

AnesthesiaController 会将前向钩子连接到每个 MTLNLayer 和 GlobalCoherenceLayer。在水平 $\ell \in [0, 1]$ 时：

$$\text{MT-DL: } (\text{out}, h_{\text{last}}) \leftarrow ((1 - \ell) \cdot \text{out}, (1 - \ell) \cdot h_{\text{last}}), \quad (13)$$

$$\text{Coherence: } \mathbf{x}_{\text{out}} \leftarrow \mathbf{x}_{\text{in}} + (1 - \ell)(\mathbf{x}_{\text{out}} - \mathbf{x}_{\text{in}}). \quad (14)$$

没有修改任何权重。上下文管理器：with anesthetize(model, level): ...

4.3 信息整合代理

精确的 IIT- Φ 是 #P-hard 的 [?]. 我们引入了两种互补的估计器。

KSG kNN 代理 $\hat{\Phi}$. 具有 L^∞ 度量的 Kraskov–Stögbauer–Grassberger (KSG) 熵估计器 [?]:

$$\hat{H}(X) = -\psi(k) + \psi(N) + d \cdot \langle \log(2\varepsilon_i) \rangle, \quad (15)$$

其中 ε_i 是从样本 i 到其第 k 个最近邻的 L^∞ 距离。整合代理为:

$$\hat{\Phi}(\mathbf{h}) = \sum_{j=1}^K \hat{H}(s_j) - \hat{H}(\mathbf{h}), \quad (16)$$

应用于最终隐藏状态 $\mathbf{h} \in \mathbb{R}^d$ 的 K 路连续划分 $(s_1, \dots, s_K)$ 。对 $n_{\text{batches}} = 10$ 个独立随机批次进行平均 (方差 $\propto 1/\sqrt{10 \cdot BT}$)。默认值: $K = 4$, $k = 3$ 。

高斯总相关 Φ_G . 在高斯假设下, 协方差为 Σ 的 K 划分随机向量 $\mathbf{h}$ 的总相关 (多重信息) 为:

$$\Phi_G(\mathbf{h}) = \frac{1}{2} \left[\sum_{j=1}^K \log \det \Sigma_j - \log \det \Sigma \right], \quad (17)$$

其中 $\Sigma_j \in \mathbb{R}^{(d/K) \times (d/K)}$ 是相关矩阵 Σ 对应于分区 j 的对角块。根据熵的次可加性 (信息链式法则), $\Phi_G \geq 0$ 严格成立, 当且仅当 K 个部分相互独立时等式成立。

我们利用恒等式 $\log \det M = \sum_i \log \lambda_i(M)$ 使用 `torch.linalg.eigvalsh` 来评估 (17), 其复杂度为 $O(d^3)$ (而 kNN 为 $O(N^2 d)$)。对角 Tikhonov 正则化 $\rho = (\text{tr } \Sigma / d) \times 0.01$ 确保了当 $N < d$ 时的正定性。

此外, 我们报告了有效秩 (参与比):

$$\text{PR}(\mathbf{h}) = \frac{(\sum_i \lambda_i)^2}{\sum_i \lambda_i^2}, \quad (18)$$

以及整合比率 $\Phi_G / H_{\text{whole}} \in [0, 1]$ ——可归因于跨分区相关的总微分熵得分数的比例。两种估计器在成本与稳定性上不同: Φ_G 为 $O(d^3)$ (单次特征分解, 约 0.3s), 构造上非负, 在小样本下数值稳定; 而 $\hat{\Phi}$ (KSG kNN) 为 $O(N^2 d)$, 在小 N 下负偏 [?]. 在本版本使用的 toy 规模下, $\hat{\Phi}$ 的绝对值不具有意义——只有它在麻醉钩子下的变化方向才有意义 (见 AVP 一节)。

4.4 麻醉测试

定义 4.1 (麻醉测试). 令 $\Phi \in \{\hat{\Phi}, \Phi_G\}$ 作为积分代理。如果体系结构在深度 δ 通过麻醉测试, 记 $\ell = (\kappa - 1)/9$:

- (i) $\Phi(\kappa_{\text{max}})/\Phi(\kappa = 1) \leq 1 - \delta$ (幅度坍缩), 以及
- (ii) 所有的 i 都有 $\Phi(\kappa_i) \geq \Phi(\kappa_{i+1})$ (单调递减),




图 2: 评估结果摘要 (toy 规模, 5 种子均值 $\pm$ 标准差): 左: Selective Copy 在 $T = 37$ 的留出序列精确匹配率; 中: 长上下文扫描——序列精确率随 T_{total} 变化; 右: 麻醉验证协议响应——只有 MT-LNN 的 $\hat{\Phi}$ 在麻醉钩子下移动 (基线无钩子, $\Delta\hat{\Phi} = 0$)。数字由 `benchmarks/multi_seed_sweep.py` 复现。

对于 $\kappa_{max} = 10$ 。默认 $\delta = 0.7$ ，匹配全身麻醉下神经复杂度的 70–80% 抑制 [?]

Transformer 和普通的 LNN 缺乏 MT 相干参数，在 AVP 下表现出几乎恒定的 $\hat{\Phi}$ 。只有 MT-LNN（其中 ℓ 直接调节动态相关参数）能够表现出微观生物学麻醉特征性的单调 $\hat{\Phi}$ -vs- κ 坍塌。

4.5 实验设置与诚实声明

本版本的所有结果均在单张消费级 RTX 5060 笔记本 GPU (8 GB) 上复现，5 个随机种子取均值 $\pm$ 标准差。我们诚实报告：在当前可及的算力规模下，三种架构在合成检索任务上大体相当，并非某一架构显著占优。

4.6 语言建模 (WikiText-103)

表 1: WikiText-103 词级别验证困惑度， $\approx 84M$ 规模，相同 token 预算 (3000 优化步 ≈ 1 epoch，全局 batch 32，序列 512)，单张 8 GB GPU。这些是算力受限的等预算快照，非完全收敛。用 `benchmarks/wikitext_comparison.py` 复现。

Model	Params	验证 PPL $\downarrow$	Tok/s $\uparrow$	峰值显存 GB
Transformer	84.5M	326.3	18 166	3.4
LNN	92.2M	343.5	17 195	3.5
MT-LNN	84.2M	214.8	5 674	6.9

在相同优化步预算下，MT-LNN 的验证困惑度 (214.8) 显著低于 Transformer (326.3，低 34%) 和普通 LNN (343.5) ——这是 MT-LNN 的归纳偏置在自然语言上首次给出真实、可复现的优势。

两点诚实的说明：(i) 三者都远未收敛（单 epoch 后困惑度仍在数百量级），故这是样本效率快照而非最终 LM 质量；(ii) MT-LNN 每 token 慢约 $3.2\times$ （5.7K vs 18K tok/s）且显存翻倍，故在等 *wall-clock* 预算下差距会缩小。更长训练与等 *wall-clock* 对比是自然的下一步。LRA 近来被指出主要反映局部性偏置而非真正的长程建模能力，本版本不纳入。

4.7 长文本 Selective Copy

在全序列重算解码（对无 KV cache 的模型）和 5 种子下，三种约 200K 参数的架构在 Selective Copy 上大体相当，MT-LNN 的优势并不随序列长度增长。

表 2: Selective Copy 留出序列精确匹配率（%），5 种子均值 $\pm$ 标准差。MT-LNN 在 $T = 37$ 略优（种子方差重叠），在 $T = 101/229$ 反被基线超过且训练不稳定。

T_{total}	Transformer	LNN	MT-LNN
37	56.0 $\pm$ 3.4	52.6 $\pm$ 4.8	58.3 $\pm$ 13.9
101	46.3 $\pm$ 6.1	51.7 $\pm$ 10.4	41.5 $\pm$ 13.0
229	22.3 $\pm$ 2.2	27.7 $\pm$ 6.6	3.9 $\pm$ 4.9

诚实的负面结论。在相同算力下三架构大体相当，MT-LNN 的优势并不随序列长度增长：它在 $T = 37$ 至多打平，在更长序列上被两个基线超过，且训练在 $T = 229$ 时崩溃（3.9% $\pm$ 4.9%，接近随机）。Selective Copy 本就是 attention 能近乎完美解决的任务 [Gu & Dao, 2023]，不是递归模型应当胜出的场景。

4.8 状态跟踪（Parity）

真正应体现递归归纳偏置的是状态跟踪任务：计算滚动 parity 需要维护一个持久累加器，固定深度的软注意力被证明无法在无思维链下完成 [Hahn, 2020, Merrill & Sabharwal, 2023]，而递归状态原则上可以精确跟踪。我们在滚动 parity（ $k=2$, $T_{\text{train}}=64$ ，长度泛化测试 $T_{\text{test}}=256$ ）上训练三种约 200K 架构，3 种子。

表 3: 滚动 parity 下一 token 准确率，3 种子均值 $\pm$ 标准差。随机基线为 0.50。当前 toy 配置下三种架构均未学会该任务。

Model	分布内 ($T=64$)	长度泛化 ($T=256$)
Transformer	0.501 $\pm$ 0.001	0.501 $\pm$ 0.002
LNN	0.501 $\pm$ 0.001	0.501 $\pm$ 0.002
MT-LNN	0.501 $\pm$ 0.001	0.501 $\pm$ 0.002

诚实的负面结果。在此小规模与训练预算下，MT-LNN 并未展现预期的递归优势——三者都停

留在随机水平；更强的训练配方（序列缩短到 $T = 16$ 、训练加长到 15 000 步）同样让三者都停在 ≈ 0.50 。Parity 以难优化著称（典型的 grokking 任务，常需长训练课程与权重衰减调优）。MT-LNN 的原丝状态能否在更好的训练配方下学会 parity、并进而在 attention 无法胜任的更长序列上泛化，是**证实本架构核心主张最关键的未决实验**，我们明确将其列为未来工作，而非报告一个不成熟的胜利。

4.9 时序预测 (ETT)

液态架构在实值时序回归上应有归纳偏置优势。我们在 ETTh1（小时级电力变压器数据集，Zhou 等 2021）上测试：univariate 油温，输入长度 $L = 96$ ，预测 $H = 96$ ，标准 12/4/4 月划分，3 seed。三种 backbone 共用完全相同的 forecasting head（连续输入投影 + 位置编码 + 末步线性头），只有序列混合 backbone 不同。

表 4: ETTh1 univariate 预测，test MSE/MAE（3 seed 均值 $\pm$ 标准差）。越低越好。

Model	test MSE	test MAE
Transformer	0.170 ± 0.023	0.343 ± 0.034
LNN (纯 CfLTC)	0.156 ± 0.003	0.330 ± 0.002
MT-LNN (完整)	0.200 ± 0.052	0.381 ± 0.057

诚实的发现。 液态成分有帮助——纯 LNN (CfLTC) 误差最低且方差远小于其他；但完整微管机制 (GWTB、GlobalCoherence、13 协议丝横向耦合) 在此是净负担，误差最高、方差最大。结合 WikiText 结果（完整架构获胜），诚实的结论是：MT-LNN 的附加复杂度在语言建模上有回报，但在低维时序回归上不如纯液态归纳偏置。我们如实报告，而非只挑对自己有利的任务。

4.10 不规则采样信号的连续时间建模

液态/连续时间网络的定义性能力是利用非均匀采样数据的时间戳。CfLTC 递归中状态按 $\exp(-\Delta t/\tau)$ 衰减；更大的真实时间间隔 Δt 应导致更多遗忘。我们的实现现已将逐步 Δt 张量贯穿整个栈 (MTLNNModel $\rightarrow$ MTLNNBlock $\rightarrow$ MTLNNLayer $\rightarrow$ resonance)：不提供 Δt 时 decay 为常数 $\exp(-1/\tau)$ （与 LM 路径逐位一致，验证差异为 0）；提供时 decay 变为逐步 $\exp(-\Delta t/\tau)$ ，扫描从 constant- A 特化切换到 general 并行扫描。

我们用一个对 MT-LNN 自身的消融来隔离该机制的价值。连续信号 $x(t) = \sin(2\pi ft + \phi)$ (f, ϕ 每序列随机) 在非均匀时刻采样 ($\Delta t \sim \mathcal{U}[0.05, 0.5]$, $L = 48$)；模型须在给定 query 间隔下预测下一个观测值。一个变体只把 Δt 作为输入通道；另一个额外把它喂进 CfLTC decay。

正面结果。 把 Δt 喂进 decay 将 MSE 从 0.204 降到 0.180——相对改善 11.7%，且三个 seed 全部一致 ($0.156 < 0.190$, $0.184 < 0.213$, $0.200 < 0.209$)，并给出整体最优变体。由于两行共享权重、架构和 Δt -作特征的访问，增益专门归因于连续时间 decay 机制而非额外信息。这直接证明：一旦架

表 5: 不规则采样下一值预测, test MSE (3 seed 均值 $\pm$ 标准差)。最后两行唯一差别是 Δt 是否进入 CfLTC decay。

变体	test MSE
Transformer (Δt 作特征)	0.189 $\pm$ 0.024
LNN (Δt 作特征)	0.217 $\pm$ 0.009
MT-LNN (Δt 仅作特征)	0.204 $\pm$ 0.012
MT-LNN + Δt 进 decay	0.180 $\pm$ 0.023

构被允许看到真实流逝时间, CfLTC 先验就发挥了实际作用。我们接着检验该效应能否迁移到真正的不规则临床基准。

PhysioNet-2012 ICU 死亡率预测。 我们在液态网络领域权威的不规则采样临床基准上评估:4000 例 ICU 住院 (set-a), 每例是 48h 内 (Δt , 变量, 值) 的 event stream, 36 个时序变量, 预测院内死亡 (13.9% 阳性)。使用相同四变体, 配 event-embedding 编码器 (变量 embedding + 值投影 + 位置编码) 和 masked-mean-pool 分类头, 3 seed, 报告 AUROC 与 AUPRC。

表 6: PhysioNet-2012 院内死亡率预测 (3 seed 均值 $\pm$ 标准差)。AUROC 与液态网络文献中 CfC/LTC 报告的 0.80–0.85 一致, 验证了实验设置的合理性。

变体	AUROC $\uparrow$	AUPRC $\uparrow$
Transformer	0.797 $\pm$ 0.018	0.410 $\pm$ 0.062
LNN	0.777 $\pm$ 0.039	0.357 $\pm$ 0.063
MT-LNN (Δt 仅作特征)	0.823 $\pm$ 0.025	0.441 $\pm$ 0.052
MT-LNN + Δt 进 decay	0.814 $\pm$ 0.034	0.422 $\pm$ 0.056

两个诚实的发现。 (i) 完整 MT-LNN 架构在这个真实临床任务上确实领先 (AUROC 0.823 vs Transformer 0.797、纯 LNN 0.777), 绝对数值与 CfC/LTC 文献一致——在一个重要基准上的真实正面结果。 (ii) 但 Δt 进 decay 机制在此没有增益 ($0.814 \leq 0.823$, 方差内) ——与合成任务相反。最可能的解释是:PhysioNet 上 Δt 已作为输入特征可被模型利用, 再注入 decay 是冗余; 且临床测量的真实时间依赖比合成信号的纯连续时间结构更丰富, 简单的 $\exp(-\Delta t/\tau)$ 核并非关键优势。诚实的结论是: 连续时间 decay 是任务依赖的——当目标严格是流逝时间的函数时 (合成) 决定性, 当时间信号已被特征捕获时 (临床) 冗余。我们同时报告两者, 而非从有利情形过度推广。

4.11 预训练 LLM 上的残差适配器

我们还将 MT-LNN 作为冻结底座的残差适配器验证: 把一个小 MT-LNN 模块 (12.4M 可训练参数, 占底座 2.5%) 每隔四层插入 Qwen2.5-0.5B-Instruct, 在单张 8 GB GPU 上微调 500

步。底座与适配器在短程大海捞针探针上均保持 100% 检索，推理吞吐仅下降约 10–15%，说明适配器在不破坏底座行为的前提下完成集成。更长上下文的底座-适配器困惑度/大海捞针对比正在进行；完整训练细节见 `benchmarks/adapter_qwen05_training_report.md`。

4.12 麻醉验证 (AVP)

在 toy 规模下，唯一有意义的观察是：**只有 MT-LNN 会响应**——麻醉钩子只挂在 `MTLNLayer` 和 `GlobalCoherenceLayer` 上，基线不含这些结构，故其 $\Delta\hat{\Phi}$ 恒为 0。

表 7: toy 规模下的 AVP 响应，5 种子均值。该规模下 $\hat{\Phi}$ 绝对值无意义 (KSG 小样本偏差)，只有响应本身有意义。基线无钩子。

架构模型	$\Delta\hat{\Phi}$ ($\kappa=10$ 减 $\kappa=1$)
Transformer	0.000 (无钩子)
LNN	0.000 (无钩子)
MT-LNN	$+7.68 \pm 2.89$ (有响应)

诚实的局限。在此规模下响应方向是错的： $\hat{\Phi}$ 随 κ 上升而非坍缩，故按定义 (单调下降 $\geq 70\%$) 的麻醉测试未通过。原因有二：(i) KSG 估计器在 $d=104$ 、仅约 150 样本下负偏 [?]，绝对值乃至变化方向都不可靠；(ii) 对一个微小、弱整合模型施加麻醉阻尼会把激活推向低秩流形，使部件间相关性上升。机制是真实存活的 (只有 MT-LNN 产生大而一致的 $\Delta\hat{\Phi}$)，但论文生物类比所预言的方向只能在真实规模、正基线整合的模型上检验。因此我们将 AVP 定位为**机制探针 / 架构指纹**，而非一个已通过的性能基准：有意义的通过/失败判定需要在真实规模、正基线整合的模型上进行。

5 局限性 (Limitations)

本工作存在若干重要局限，我们坦诚列出：(i) 本版本所有实验均在单张 8 GB 消费级 GPU 上完成，语言建模为算力受限的等预算快照而非完全收敛；(ii) 在合成检索与状态跟踪任务上，MT-LNN 目前未展现出超越匹配基线的优势，parity 上三者均在随机水平；(iii) AVP 在 toy 规模下方向与生物预期相反，只能定位为机制探针；(iv) 将架构扩展至 1B+ 参数、并在正整合的真实训练模型上检验麻醉主张，仍是未决工作。我们撤回了此前未经支撑的 125M 困惑度、LRA 与 89.5% 坍缩数字。

6 结论 (Conclusion)

MT-LNN 据我们所知是首个在单一 Transformer 兼容、经完整单元测试的代码库中，同时实现微管动态、全局工作区理论与麻醉验证协议的架构。它还通过逐步 Δt 衰减原生支持连续时间输入。本文的贡献主要是架构与方法学层面的：一个正确、开源的实现与一套坦诚的评测协议。

实证图景是诚实混合、任务依赖的:MT-LNN 在 WikiText-103 上样本效率显著优于匹配基线、在真实 PhysioNet-2012 ICU 死亡率基准上领先, 但纯液态层在低维时序回归上更优, 完整架构在 attention 已能解决的任务上无优势; 连续时间 Δt 机制在严格由时间驱动的信号上决定性有效, 但当 Δt 已是输入特征时冗余。麻醉钩子提供了独特的架构指纹, 但生物学预言的坍塌方向仍待更大规模验证。我们勾勒出检验意识相关主张所需的大规模实验。所有代码与权重均已开源于 <https://github.com/everest-an/01>。

参考文献

- Albantakis, L. et al. (2023). Integrated information theory (IIT) 4.0. *PLOS Computational Biology*, 19(10):e1011465.
- Blelloch, G. E. (1990). Prefix sums and their applications. *Technical Report CMU-CS-90-190*, Carnegie Mellon University.
- Baars, B. J. (1988). *A Cognitive Theory of Consciousness*. Cambridge University Press.
- Chen, R. T. Q. et al. (2018). Neural ordinary differential equations. *NeurIPS*.
- Craddock, T. J. A. et al. (2017). Anesthetic alterations of collective terahertz oscillations in tubulin correlate with clinical potency. *Scientific Reports*, 7(1):9877.
- Dehaene, S., Changeux, J.-P., & Lou, L. (2011). Experimental and theoretical approaches to conscious processing. *Neuron*, 70(2):200–227.
- Gu, A. & Dao, T. (2023). Mamba: Linear-time sequence modeling with selective state spaces. *arXiv:2312.00752*.
- Hahn, M. (2020). Theoretical limitations of self-attention in neural sequence models. *Transactions of the ACL*, 8:156–171.
- Merrill, W. & Sabharwal, A. (2023). The parallelism tradeoff: Limitations of log-precision transformers. *Transactions of the ACL*, 11:531–545.
- Hameroff, S. & Penrose, R. (2014). Consciousness in the universe: A review of the Orch OR theory. *Physics of Life Reviews*, 11(1):39–78.
- Tononi, G. (2004). An information integration theory of consciousness. *BMC Neuroscience*, 5:42.
- Wiest, C. et al. (2025). The role of microtubules in anesthetic mechanism...